

1 基础与评估

1.1 偏差-方差分解

泛化误差可分解为偏差、方差与噪声之和: $E(f; D) = \text{bias}^2(\mathbf{x}) + \text{var}(\mathbf{x}) + \varepsilon^2$ 。偏差 $\text{bias}^2(\mathbf{x}) = (\bar{f}(\mathbf{x}) - y)^2$: 度量学习算法的期望预测与真实结果的偏离程度 (拟合能力)。方差 $\text{var}(\mathbf{x}) = \mathbb{E}_D[(f(\mathbf{x}; D) - \bar{f}(\mathbf{x}))^2]$: 度量同样大小的训练集变动导致的性能变化 (稳定性)。噪声 ε^2 : 数据本身的难度。

1.2 高斯分布

$\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)$, 其中 $\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{d/2}|\boldsymbol{\Sigma}|^{1/2}} \exp(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}))$ 。

1.3 性能度量

查准率 (Precision): $P = \frac{TP}{TP+FP}$ 查全率 (Recall): $R = \frac{TP}{TP+FN}$
F1-Score: $\frac{2 \times P \times R}{P+R}$ ROC 与 AUC: ROC 曲线坐标为 (FPR, TPR), AUC 为曲线下覆盖面积, 衡量排序质量。

2 线性模型与 SVM

2.1 逻辑回归 (Logistic Regression)

使用对数几率函数 (Sigmoid) 逼近后验概率: $y = \frac{1}{1+e^{-(\mathbf{w}^T \mathbf{x} + b)}}$
对数几率 $\ln \frac{y}{1-y} = \mathbf{w}^T \mathbf{x} + b$ 。优化目标 (最大化对数似然):
 $\min_{\mathbf{w}, b} \sum_{i=1}^m \ln(1 + e^{-y_i(\mathbf{w}^T \mathbf{x}_i + b)})$ (假设 $y_i \in \{-1, +1\}$ 或对应调整公式)。

2.2 支持向量机 (SVM)

基本型: 最大化间隔 $\gamma = \frac{2}{\|\mathbf{w}\|} \cdot \min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2$, s.t. $y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$ 对偶问题: 引入拉格朗日乘子 $\alpha_i \geq 0$: $\max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j$ s.t. $\sum_{i=1}^m \alpha_i y_i = 0, \alpha_i \geq 0$
解得 $\mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i$ 。支持向量满足 $\alpha_i > 0$ 。软间隔: 允许部分样本出错, 引入松弛变量 ξ_i 和惩罚参数 C : $\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i$ 核技巧: $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$, 解决非线性可分。常用高斯核 $\kappa(\mathbf{x}, \mathbf{y}) = \exp(-\frac{\|\mathbf{x}-\mathbf{y}\|^2}{2\sigma^2})$ 。

3 集成学习

误差-分歧分解: $E = \bar{E} - \bar{A}$ (集成误差 = 个体平均误差 - 个体平均分歧)。**AdaBoost** 最小化指数损失 $L(y, f(x)) = e^{-yf(x)}$ 。
更新权重: 若 h_t 错误率 ϵ_t , 则权重 $\alpha_t = \frac{1}{2} \ln \frac{1-\epsilon_t}{\epsilon_t}$ 。样本分布更新: 错分样本权重增加 $D_{t+1}(\mathbf{x}) \propto D_t(\mathbf{x}) e^{-\alpha_t y_i h_t(\mathbf{x}_i)}$ 。

Bagging & Random Forest Bagging: Bootstrap 采样训练基学习器, 投票/平均。Random Forest: Bagging + 属性随机选择 (基尼指数选择划分时只考虑随机子集)。

4 聚类

4.1 距离度量

四个性质: 非负性、同一性、对称性、直递性

无序属性: 令 $m_{u,a}$ 表示属性 u 上取值为 a 的样本数, $m_{u,a,i}$ 表示在第 i 个样本簇中在属性 u 上取值为 a 的样本数, k 为样本簇数, 则属性 u 上两个离散值 a 与 b 之间的 VDM 距离为

$$VDM_p(a, b) = \sum_{i=1}^k \left| \frac{m_{u,a,i}}{m_{u,a}} - \frac{m_{u,b,i}}{m_{u,b}} \right|^p$$

4.2 分类

- 原型聚类: k-means, 学习向量量化, 高斯混合聚类
 - k-means**: 1. 初始化 k 个中心 $\boldsymbol{\mu}_j$ 。2. E 步: 分配样本到最近中心 $C_j = \{\mathbf{x}_i | \|\mathbf{x}_i - \boldsymbol{\mu}_j\| \leq \|\mathbf{x}_i - \boldsymbol{\mu}_{j'}\|\}$ 。3. M 步: 更新中心 $\boldsymbol{\mu}_j = \frac{1}{|C_j|} \sum_{\mathbf{x} \in C_j} \mathbf{x}$ 。4. 重复直到收敛。
 - 学习向量量化 (LVQ)**: 约等于 k-means 但是数据带标记。计算每个样本到各中心 p 的距离, 如果 x 和 p 标签相同, $p' = p + \eta(x - p)$, 否则 $p' = p - \eta(x - p)$ 。
 - 高斯混合模型 (GMM)**: 假设 $P(\mathbf{x}) = \sum_{i=1}^k \alpha_i p(\mathbf{x}|\boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)$ 。使用 **EM 算法** 求解: 1. 最大化似然函数 $LL = \sum_{j=1}^m \ln(\sum_{i=1}^k \alpha_i p(\mathbf{x}_j|\boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i))$ 2. E 步: 计算后验概率 $\gamma_{ji} = P(z_j = i|\mathbf{x}_j) = \frac{\alpha_i p(\mathbf{x}_j|\boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)}{\sum_l \alpha_l p(\mathbf{x}_j|\boldsymbol{\mu}_l, \boldsymbol{\Sigma}_l)}$ 。3. M 步: 更新参数 $\boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i, \alpha_i$ 。 $\boldsymbol{\mu}_i^{new} = \frac{1}{N_i} \sum_{j=1}^m \gamma_{ji} \mathbf{x}_j$ 。 $\boldsymbol{\Sigma}_i^{new} = \frac{1}{N_i} \sum_{j=1}^m \gamma_{ji} (\mathbf{x}_j - \boldsymbol{\mu}_i^{new})(\mathbf{x}_j - \boldsymbol{\mu}_i^{new})^T$ 。 $\alpha_i^{new} = \frac{N_i}{m}$
- 密度聚类: DBSCAN, OPTICS, DENCLUE
 - DBSCAN**: 核心对象: 邻域内至少包含 MinPts 个样本的点。密度直达: 位于核心对象邻域内的点。密度可达: 存在一条由密度直达连接的路径。密度相连: 存在共同密度可达的点。
- 层次聚类: AGNES, DIANA
 - AGNES**: 每个样本作为一个簇, 合并两个最近的簇直到大一统。

5 降维

5.1 PCA (主成分分析)

目标: 最近重构性或最大可分性。解: 协方差矩阵 $\mathbf{X}\mathbf{X}^T$ 的前 d' 个最大特征值对应的特征向量。 $\mathbf{X}\mathbf{X}^T \mathbf{w}_i = \lambda_i \mathbf{w}_i$ 重构: $\hat{\mathbf{x}} = \sum_{i=1}^{d'} z_i \mathbf{w}_i$ 。

步骤: 1. 数据中心化 $\hat{X} = X - \bar{X}$ 。2. 计算协方差矩阵 $\Sigma = \hat{X}^T \hat{X}$ 。3. 求解特征值与特征向量。 $\det(\Sigma - \lambda I) = 0$ 解得特征值, 依次代入特征值计算 $(\Sigma - \lambda I)v = 0$ 得到特征向量。4. 选择前 d' 个特征向量构成投影矩阵 $\mathbf{W} = [\mathbf{v}_1, \dots, \mathbf{v}_{d'}]$ 。5. 投影降维: $\mathbf{Z} = \hat{X}\mathbf{W}$ 。

5.2 流形学习

ISOMAP: MDS + 测地线距离 (最短路径算法)。**LLE**: 保持局部线性关系 (重构权重)。

- 找近邻: 对 \mathbf{x}_i 找 k 近邻集合 Q_i 。
- 算权重: 最小化重构误差求权重 w_{ij} (保持 \mathbf{x}_i 由邻居线性表示)。 $\min_{\mathbf{w}} \sum_i \|\mathbf{x}_i - \sum_{j \in Q_i} w_{ij} \mathbf{x}_j\|^2$, s.t. $\sum_{j \in Q_i} w_{ij} = 1$

3. 求坐标: 固定 w_{ij} , 求低维坐标 \mathbf{z}_i 。 $\min_{\mathbf{Z}} \sum_i \|\mathbf{z}_i - \sum_{j \in Q_i} w_{ij} \mathbf{z}_j\|^2 = \text{tr}(\mathbf{Z}\mathbf{M}\mathbf{Z}^T)$ 其中 $\mathbf{M} = (\mathbf{I} - \mathbf{W})^T (\mathbf{I} - \mathbf{W})$ 。

4. 解: \mathbf{M} 的最小 d' 个非零特征值对应的特征向量。

5.3 距离度量学习

核心: 学习马氏距离矩阵 \mathbf{M} , 使度量适应任务。 $\text{dist}_{\text{mah}}^2(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i - \mathbf{x}_j)^T \mathbf{M} (\mathbf{x}_i - \mathbf{x}_j) = \|\mathbf{x}_i - \mathbf{x}_j\|_{\mathbf{M}}^2$ 其中 $\mathbf{M} \succeq 0$ (半正定对称矩阵)。

基于约束的方法: 给定必连集合 \mathcal{M} (同类) 和勿连集合 \mathcal{C} (异类), 求解凸优化: $\min_{\mathbf{M}} \sum_{(\mathbf{x}_i, \mathbf{x}_j) \in \mathcal{M}} \|\mathbf{x}_i - \mathbf{x}_j\|_{\mathbf{M}}^2$ s.t. $\sum_{(\mathbf{x}_i, \mathbf{x}_k) \in \mathcal{C}} \|\mathbf{x}_i - \mathbf{x}_k\|_{\mathbf{M}}^2 \geq 1, \mathbf{M} \succeq 0$

代表性算法

- NCA (近邻成分分析)**: 优化随机近邻分类器的留一法 (LOO) 正确率。概率 $p_{ij} \propto \exp(-\|\mathbf{x}_i - \mathbf{x}_j\|_{\mathbf{M}}^2)$ 。
- LMNN (最大间隔近邻)**:
 - 拉近: 最小化同类 k 近邻的距离。
 - 推开: 保证异类样本与同类近邻之间有间隔 (Margin)。

6 特征选择与稀疏学习

6.1 特征选择

信息增益公式: $\text{Gain}(A) = \text{Ent}(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Ent}(D^v)$ 其中 $\text{Ent}(D) = -\sum_{k=1}^K \frac{|D_k|}{|D|} \log_2 \frac{|D_k|}{|D|}$ 。

- 过滤式 (Filter)-Relief**: 先用特征选择过程过滤原始数据, 再进行模型训练; 特征选择与后续学习器无关
- 包裹式 (Wrapper)-LVW**: 直接针对给定学习器进行优化, “量身定做” 特征子集。性能通常更好, 但计算开销大
- 嵌入式 (Embedded)-LASSO&PGD**: 将特征选择过程与学习器训练过程融为一体, 通常通过正则化 (岭回归 $(+\lambda \frac{1}{2} \|\mathbf{w}\|_2^2)$, LASSO $(+\lambda \|\mathbf{w}\|_1)$) 实现

6.2 稀疏学习

- 字典学习**: 将稠密数据转化为稀疏表示。学习字典 B 和稀疏系数 A 。优化目标: $\min_{B, A} \sum_{i=1}^m \|\mathbf{x}_i - B\mathbf{a}_i\|_2^2 + \lambda \|\mathbf{a}_i\|_1$ 。交替优化 B 和 \mathbf{a}_i 。
- 压缩感知**: 利用部分采样恢复全信号。 $y = \Phi x$ 。条件: 信号稀疏, 采样矩阵满足限定等距性。求解 $\min_s \|s\|_1$ s.t. $y = \Phi \Psi s$, 从 y 中恢复稀疏信号 s , 进而恢复 x 。
- 矩阵补全**: 解决推荐系统等场景下的数据缺失问题。优化: $\min_X \|X\|_*$ s.t. $X_{ij} = A_{ij}, (i, j) \in \Omega$ 。其中 $\|X\|_* = \sum \sigma_i$ 。

7 半监督学习

假设: 聚类假设 (同簇同类)、流形假设 (邻近同类)。

7.1 生成式方法

假设 $P(\mathbf{x}, y) = \sum_k \alpha_k p(\mathbf{x}|\boldsymbol{\theta}_k)$, 将未标记数据视为隐变量, 最大化对数似然函数: $\ln p(D_l \cup D_u) =$

$\sum_{(x_j, y_j) \in D_l} \ln(\sum_{i=1}^k \alpha_i p(x_j | \mu_i, \Sigma_i) p(y_j | \Theta = i, x_j)) + \sum_{x_j \in D_u} \ln(\sum_{i=1}^k \alpha_i p(x_j | \mu_i, \Sigma_i))$. 求解 (EM 算法)

7.2 半监督 SVM (S3VM / TSVM)

原理: 在最大化间隔的同时, 尽量使超平面穿过数据低密度区域 (TSVM)。优化目标: $\min_{w, b, \hat{y}, \xi} \frac{1}{2} \|w\|_2^2 + C_l \sum_{i=1}^l \xi_i + C_u \sum_{i=l+1}^m \xi_i$ s.t. 对 D_l 满足标准约束; 对 D_u 满足 $\hat{y}_i (w^T x_i + b) \geq 1 - \xi_i$ 。求解策略: 1. 用 D_l 训练初始 SVM。2. 对 D_u 进行预测指派伪标记 \hat{y} 。3. 迭代: 找出可能错误的伪标记样本 ($y_i \hat{y}_i < 0$ 且 $\xi > 0$), 交换其标记, 重新求解, 逐步增大 C_u 至 C_l 。

7.3 图半监督学习 (Graph-Based Methods)

构图: 节点为样本, 边权重 W_{ij} 为相似度 (如高斯核)。能量函数: $E(f) = \frac{1}{2} \sum_{i,j} W_{ij} (f(x_i) - f(x_j))^2 = f^T (D - W) f$ 。闭式解: 令 $\frac{\partial E}{\partial f_u} = 0$, 得 $f_u = (D_{uu} - W_{uu})^{-1} W_{ul} f_l = (I - P_{uu})^{-1} P_{ul} f_l$ 。迭代式标记传播 (Label Propagation): $F(t+1) = \alpha S F(t) + (1 - \alpha) Y$ 其中 $S = D^{-1/2} W D^{-1/2}$, 收敛解为 $F^* = (1 - \alpha)(I - \alpha S)^{-1} Y$ 。

7.4 基于分歧的方法 (Disagreement-based Methods)

代表: 协同训练 (Co-training)。条件: 数据拥有两个充分且条件独立的视图 (View)。流程: 1. 在两个视图上分别训练分类器 h_1, h_2 。2. 每个分类器挑选置信度最高的未标记样本 (正/负), 赋予伪标记并加入对方的训练集。3. 迭代更新。

7.5 半监督聚类 (Semi-Supervised Clustering)

监督信息类型:

- 约束: 必连 (Must-link, M) 与勿连 (Cannot-link, C)。
- 标记样本: 少量样本已知所属簇。

算法: 1. 约束 k-means: 在分配簇时, 若违反 M 或 C 约束, 则不分配或分配给次优簇。2. 约束种子 k-means: 用有标记样本初始化簇中心 $\mu_j = \frac{1}{|S_j|} \sum_{x \in S_j} x$ 。

8 概率图模型

8.1 隐马尔可夫模型 (HMM)

动态贝叶斯网, 由隐藏状态序列 y 和观测变量序列 x 组成。

- 三组参数 $\lambda = [A, B, \pi]$:
 - 状态转移概率 $A: a_{ij} = P(y_{t+1} = s_j | y_t = s_i)$
 - 输出观测概率 $B: b_{ij} = P(x_t = o_j | y_t = s_i)$
 - 初始状态概率 $\pi: \pi_i = P(y_1 = s_i)$
- 齐次马尔可夫假设: $P(y_t | y_{t-1}, \dots, y_1) = P(y_t | y_{t-1})$ 。
- 观测独立性假设: $P(x_t | y_t, \dots) = P(x_t | y_t)$ 。

8.2 马尔可夫随机场 (MRF)

基于无向图, 使用团 (Clique) 和势函数 (Potential Function) 定义联合概率。联合概率分布: $P(\mathbf{x}) = \frac{1}{Z} \prod_{Q \in \mathcal{C}} \psi_Q(\mathbf{x}_Q)$ 其中 \mathcal{C} 为极大团集合, ψ_Q 为势函数 (通常 $\psi_Q \geq 0$), $Z = \sum_{\mathbf{x}} \prod_{Q \in \mathcal{C}} \psi_Q(\mathbf{x}_Q)$ 为规范化因子。马尔可夫性:

- 全局: 给定分离集 x_C , 则 $x_A \perp x_B | x_C$ 。
- 局部/成对: 非邻接节点在给定其他节点条件下独立。

8.3 条件随机场 (CRF)

判别式无向图模型, 对条件分布 $P(\mathbf{y} | \mathbf{x})$ 建模。链式 CRF (线性链): $P(\mathbf{y} | \mathbf{x}) = \frac{1}{Z} \exp(\sum_j \sum_i \lambda_j t_j(y_{i+1}, y_i, \mathbf{x}, i) + \sum_k \sum_i \mu_k s_k(y_i, \mathbf{x}, i))$ 其中 t_j 为转移特征函数, s_k 为状态特征函数。

8.4 模型推断 (Inference)

推断的核心是计算边际分布或条件分布。

- 精确推断:
 - 变量消去法 (Variable Elimination): 利用乘法对加法的分配律, 将全局求和转化为局部求和, 实质是动态规划。
 - 信念传播 (Belief Propagation): 通过节点间传递消息 $m_{ij}(x_j)$ 计算边际分布。节点 x_i 的边际分布正比于接收消息的乘积。
- 近似推断:
 - 采样法: 通过构造平稳分布为目标分布 $p(\mathbf{x})$ 的马尔可夫链来产生样本。Metropolis-Hastings (MH) 算法: 1. 根据 $Q(\mathbf{x}^* | \mathbf{x}^{t-1})$ 采样候选 \mathbf{x}^* 。2. 计算接受率 $\alpha = \min(1, \frac{p(\mathbf{x}^*) Q(\mathbf{x}^{t-1} | \mathbf{x}^*)}{p(\mathbf{x}^{t-1}) Q(\mathbf{x}^* | \mathbf{x}^{t-1})})$ 。3. 以概率 α 接受 \mathbf{x}^* 作为 \mathbf{x}^t 。吉布斯采样 (Gibbs Sampling): MH 的特例。每次固定其他变量, 仅对一个变量 x_i 根据 $p(x_i | \mathbf{x}_{\setminus i})$ 进行采样。
 - 变分推断 (Variational Inference): 使用简单分布 $q(\mathbf{z})$ 逼近复杂后验分布 $p(\mathbf{z} | \mathbf{x})$ 。目标: 最小化 KL 散度 $KL(q || p)$, 等价于最大化证据下界 (ELBO)。 $\ln p(\mathbf{x}) = \mathcal{L}(q) + KL(q || p)$ 平均场理论: 假设 $q(\mathbf{z}) = \prod_i q_i(z_i)$, 最优解满足 $\ln q_j^*(z_j) = \mathbb{E}_{i \neq j} [\ln p(\mathbf{z}, \mathbf{x})] + \text{const}$ 。

9 规则学习

序贯覆盖 (Sequential Coverage): 逐条学习规则, 覆盖正例并移除, 直到覆盖所有正例。剪枝: 预剪枝 (似然率)、后剪枝 (REP, IREP, RIPPER)。一阶规则 (FOIL): 使用一阶逻辑 (谓词)。FOIL 增益: $\text{Gain} = \hat{m}_+ (\log_2 \frac{m_+}{\hat{m}_+ + \hat{m}_-} - \log_2 \frac{m_+}{m_+ + m_-})$ 。 m_+ 是标记正例中被规则判定为正例, m_- 是标记负例中被规则判定为正例。

冲突消解: 顺序规则、缺省规则、元规则。

归纳逻辑程序设计 (ILP):

- 最小一般泛化 (LGG): 寻找覆盖两个例子的最特殊的一般规则。
- 逆归结: 演绎的逆过程。
 - 吸收: $\frac{p \leftarrow A \wedge B}{p \leftarrow q \wedge B} \frac{q \leftarrow A}{q \leftarrow A}$ 辨识: $\frac{p \leftarrow A \wedge B}{q \leftarrow B} \frac{p \leftarrow A \wedge q}{p \leftarrow A \wedge q}$
 - 内构: $\frac{p \leftarrow A \wedge B}{q \leftarrow B} \frac{p \leftarrow A \wedge C}{p \leftarrow A \wedge q} \frac{q \leftarrow C}{q \leftarrow C}$ 互构: $\frac{p \leftarrow A \wedge B}{p \leftarrow r \wedge B} \frac{q \leftarrow A \wedge C}{r \leftarrow A} \frac{q \leftarrow r \wedge C}{q \leftarrow r \wedge C}$

10 强化学习 (RL)

四元组 $\langle X, A, P, R \rangle$ 。目标: 最大化累积回报 $\mathbb{E}[\sum \gamma^t r_t]$ 。

10.1 K-摇臂赌博机 (K-Armed Bandit)

单步强化学习, 最大化单步奖赏。

- ϵ -贪心: 以 ϵ 概率随机探索, 以 $1 - \epsilon$ 概率利用。
- 增量更新公式: $Q_n(k) = Q_{n-1}(k) + \frac{1}{n} (v_n - Q_{n-1}(k))$ 。
- Softmax: 基于概率分布选择动作, 概率 $P(k) = \frac{e^{Q(k)/\tau}}{\sum_i e^{Q(i)/\tau}}$ (τ 为温度参数)。

10.2 值函数与 Bellman 方程

状态值函数: $V^\pi(x) = \mathbb{E}_\pi[\sum \gamma^t r_t | x_0 = x]$ 。动作值函数: $Q^\pi(x, a) = \mathbb{E}_\pi[\sum \gamma^t r_t | x_0 = x, a_0 = a]$ 。
 $V^\pi(x) = \sum_a \pi(a|x) \sum_{x'} P(x'|x, a) [R(x, a, x') + \gamma V^\pi(x')]$
 最优 Bellman 方程: $V^*(x) = \max_a Q^*(x, a) = \max_a \sum_{x'} P(x'|x, a) [Q^*(x, a) + \gamma \sum_{x''} P(x''|x', a) [R(x', a, x'') + \gamma V^*(x'')]]$

10.3 求解算法

- 动态规划 (Model-based):
 - 策略迭代 (PI): 评估 $V^\pi \rightarrow$ 改进 $\pi'(x) = \arg \max_a Q^\pi(x, a)$ 。
 - 值迭代 (VI): 直接迭代 $V(x) \leftarrow \max_a \sum P(\dots)$ 。
- 免模型 (Model-free):
 - 蒙特卡罗 (MC): 采样轨迹, 均值估计期望。重要性采样: $\rho_{t:T-1} = \prod_{k=t}^{T-1} \frac{\pi(A_k | S_k)}{b(A_k | S_k)}$ 。 $V(S_t) \approx \rho_{t:T-1} G_t$
 - 时序差分 (TD): 结合 MC 和 DP。 $V(x) \leftarrow V(x) + \alpha [r + \gamma V(x') - V(x)]$ 。
 - Q-Learning (Off-policy): $Q(x, a) \leftarrow Q(x, a) + \alpha [r + \gamma \max_{a'} Q(x', a') - Q(x, a)]$ 。
 - Sarsa (On-policy): $Q(x, a) \leftarrow Q(x, a) + \alpha [r + \gamma Q(x', a') - Q(x, a)]$ 。

探索与利用: ϵ -greedy (以 ϵ 概率随机)。

10.4 值函数近似 (Value Function Approximation)

针对状态空间巨大或连续的情况, 使用参数化模型逼近值函数。

- 线性近似: $V_\theta(x) = \theta^T \phi(x)$, 其中 $\phi(x)$ 为特征向量。
- 梯度更新 (结合 TD 误差): $\theta \leftarrow \theta + \alpha (r + \gamma V_\theta(x') - V_\theta(x)) \nabla_\theta V_\theta(x)$ 对于线性近似, $\nabla_\theta V_\theta(x) = \phi(x)$ 。

10.5 模仿学习 (Imitation Learning)

利用专家示范数据 $\mathcal{D} = \{\tau_1, \tau_2, \dots\}$ 进行学习。

- 直接模仿 (Behavior Cloning): 将专家轨迹视为分类/回归训练集, 直接学习策略 $\pi: X \rightarrow A$ 。
- 逆强化学习 (IRL): 假设专家策略是最优的, 从数据中反推奖赏函数 R 。目标: 寻找 R^* 使得 $\mathbb{E}_{\pi^*}[\sum \gamma^t R^*(s_t)] \geq \mathbb{E}_\pi[\sum \gamma^t R^*(s_t)]$ 得到 R^* 后, 再通过标准 RL 算法求解最优策略。